

# Dự Đoán Giá Cổ Phiếu Trên Thị Trường Chứng Khoán Dựa Trên Bayesian-LSTM

1<sup>st</sup> Phạm Hùng Vỹ

2<sup>nd</sup> Phan Hữu Chí

3<sup>rd</sup> TS. Dương Minh Đức

Trường Đại học Công nghệ thông tin

Trường Đại học Công nghệ thông tin

Trường Đại học Công nghệ thông tin

Khoa Công nghệ phần mềm

Khoa Công nghệ phần mềm

Khoa Công nghệ phần mềm

Thành phố Hồ Chí Minh, Việt Nam

Thành phố Hồ Chí Minh, Việt Nam

Thành phố Hồ Chí Minh, Việt Nam

vyphamhung10@gmail.com

phanhuuchi105@gmail.com

ducdm@uit.com.vn

**Abstract**—Trong nghiên cứu này, chúng tôi nghiên cứu vấn đề dự đoán giá cổ phiếu trên thị trường chứng khoán bằng cách sử dụng RNN (mạng thần kinh hồi quy) với LSTM (bộ nhớ ngắn dài hạn). Tuy vậy việc lựa chọn siêu tham số cho mạng LSTM thủ công hoặc tìm kiếm ngẫu nhiên là một công việc không thú vị, mất nhiều thời gian mà không đảm bảo tính hiệu quả. Chúng tôi đề xuất thực hiện việc tối ưu hóa mô hình LSTM bằng cách tự động hoá việc tìm kiếm các siêu tham số nhờ tối ưu hoá Bayesian. Chúng tôi huấn luyện mô hình trên dữ liệu ngày của mã chứng khoán Sinopec trên sàn chứng khoán Thượng Hải để so sánh với mô hình ELSTM mà X. Pang, Y. Zhou, P. Wang, W. Lin và V. Chang [1] đưa ra. Kết quả chúng tôi đạt được chỉ số MSE là 0,0015 thấp hơn so với chỉ số MSE của mô hình ELSTM network đưa ra là 0,0019.

**Index Terms**—Thị trường chứng khoán; B-LSTM; Dự đoán giá chứng khoán; Tối ưu hoá Bayesian

## I. Giới thiệu

Thị trường chứng khoán là các tổ chức giao dịch nơi chứng khoán (vốn chủ sở hữu) và tài chính khác các công cụ như trái phiếu được cung cấp cho thương mại. Đối với cổ phiếu, thị trường thường hoạt động một giao dịch người mua đưa ra mong muốn mức giá muốn mua, người bán đưa ra mức giá muốn bán, và nếu có người mua và người bán đều có mức giá phù hợp với nhau thì giao dịch sẽ được diễn ra. Nếu không thì sẽ không có giao dịch nào diễn ra và chờ đợi một mức giá trong tương lai hoặc hết hạn.

Trong hầu hết các sàn giao dịch chứng khoán, thị trường phổ biến và dễ tiếp cận là thị trường chứng khoán (cổ phiếu), có rất ít rào cản để mọi người có thể tham gia. Thị trường chứng khoán là do đó tích cực hơn, có nhiều người chơi và do đó một phân khúc xứng đáng để nghiên cứu thêm.

Hiệu suất của thị trường chứng khoán được đo lường hàng ngày bởi một số chỉ số chính chẳng hạn như 'chỉ số tổng hợp', chỉ số thị trường chứng khoán của tất cả các cổ phiếu được giao dịch tại Sở giao dịch chứng khoán. Một chỉ số như vậy rất quan trọng trong việc không chỉ đo lường hiệu suất của các giao dịch trên thị trường chứng khoán mà còn phản ánh rõ các hoạt động kinh tế của một quốc gia và các mối quan hệ quốc tế. Cổ đông tuy nhiên không trực tiếp thực hiện giao dịch, cũng không có cuộc

họp nào giữa người mua và người bán để đàm phán. Cổ đông giao dịch bằng cách đưa ra lệnh cho các người môi giới chứng khoán của họ, những người lần lượt thực hiện các lệnh. Môi giới chứng khoán thường cũng tư vấn cho khách hàng về nơi giao dịch. Trong vai trò tư vấn của họ, một số môi giới chứng khoán căn cứ lời khuyên của họ về các nguyên tắc cơ bản của các cổ phiếu khác nhau hoặc thực hiện phân tích kỹ thuật. Tuy nhiên, không có phương pháp dự đoán nào trong số này đảm bảo lợi nhuận vì chúng thường chỉ cho thấy một xu hướng trong tương lai và khả năng tăng hoặc giảm giá chứ không phải là giá cổ phiếu dự kiến trong tương lai. Môi giới chứng khoán cần có công cụ dự đoán, để cho phép họ có một số khả năng để cung cấp lời khuyên tốt nhất họ khách hàng. Mọi người môi giới chứng khoán đều mong muốn có một công cụ dự đoán mà có thể sử dụng để phán đoán về biến động giá chính xác như là một cơ sở của đầu tư.

Đây là công cụ mọi người đều mong muốn có kể từ khi thị trường chứng khoán ra đời. Các nhà toán học từ thế kỷ XX đã đưa ra các mô hình dự đoán chuỗi thời gian như ARIMA, SARIMA. Nhưng việc áp dụng vào việc dự đoán thị trường chứng khoán còn có nhiều hạn chế. Năm 2012, mạng học sâu AlexNet đang dấu bước nhảy vọt của học sâu và đánh bại các thuật toán máy học khác. Mạng LSTM được đề xuất bởi Sepp Hochreiter và Jürgen Schmidhuber [2] vào năm 1997, với tính chất tuần tự thì việc áp dụng giải quyết các vấn đề liên quan đến chuỗi thời gian như giá chứng khoán rất hợp lý. Mãi đến năm 2013, mạng học sâu LSTM mới trở thành đối thủ đáng gờm trong các cuộc thi về nhận dạng giọng nói, chữ viết. Đến năm 2016, LSTM trở thành nền tảng không thể thiếu trong các sản phẩm mới của các hãng công nghệ khổng lồ như Google, Apple, Microsoft. Cũng nhờ đó việc cài đặt mạng LSTM trên thực tế và thử nghiệm trở nên dễ dàng hơn nhờ các công cụ phần mềm mã nguồn mở. Đặc biệt với tính chất dễ tiếp cận cũng như khả năng hiện thực hoá lợi nhuận đơn giản như thị trường chứng khoán hay tiền điện tử đã thu hút rất nhiều người tham gia với các thuật toán máy học, đặc biệt là LSTM. Nhưng việc chọn mô hình tinh chỉnh các siêu tham số là một công việc cần có kinh nghiệm chuyên sâu về cả cổ phiếu lẫn máy học. Việc thực hiện tinh chỉnh bằng tay hoặc ngẫu nhiên thì

tốn rất thời gian và chi phí mà không đảm bảo được hiệu quả. Vì vậy chúng tôi đề xuất tối sử dụng thuật toán tối ưu hoá Bayesian và tìm cách xây dựng mô hình sử dụng LSTM có nhiều khả năng tinh chỉnh kể cả cấu trúc của mô hình để thuật toán tối ưu hoá Bayesian phát huy được tối đa khả năng.

## II. Các nghiên cứu liên quan

### A. Sử dụng máy học trong dự đoán chứng khoán

Dự báo giá cổ phiếu là một việc rất phức tạp. Hầu hết các nhà môi giới chứng khoán sử dụng phân tích chuỗi kỹ thuật, cơ bản hoặc phân tích chuỗi thời gian trong việc cố gắng dự đoán giá cổ phiếu. Tuy nhiên, các chiến lược này không dẫn đến kết quả đáng tin cậy vì chúng hướng dẫn về xu hướng và không phải là giá có độ chính xác cao nhất. Cần phải sử dụng các phương pháp nâng cao để dự đoán kết quả chính xác nhất. Các nhà nghiên cứu đã sử dụng các phương pháp khác nhau và các bộ tham số đầu vào khác nhau để dự đoán giá cổ phiếu trong vài thập kỷ qua.

Adebiyi và Adewumi [3] đã xây dựng mô hình dự đoán giá cổ phiếu bằng cách sử dụng mô hình Autoregressive integrated moving average (ARIMA). Kết quả cho thấy mô hình tuy ra đời đã lâu và không yêu cầu sức mạnh tính toán nhiều nhưng ARIMA có tiềm năng mạnh mẽ để dự đoán ngắn hạn.

Xiongwen Pang, Yanqiang Zhou, Pan Wang, Weiwei Lin và Victor Chang [1] đã đưa ra mô hình Deep long-short term memory neural network (LSMN) với một lớp Embedded để dự đoán giá chứng khoán. Trong mô hình này, họ sử dụng lớp Embedded để vector hoá dữ liệu để đưa ra dự đoán qua mạng LSTM. Họ đặt tên cho mô hình này là Embedded-LSTM (ELSTM) Kết quả cho thấy mạng ELSTM rất phù hợp cho các nước đang phát triển. Kết quả đạt được cho mã cổ phiếu Sinopec trên sàn chứng khoán Thượng Hải có chỉ số MSE = 0.019, tốt hơn so với chỉ sử dụng LSTM truyền thống, MSE = 0.022

Biao Huang, Qiao Ding, Guozi Sun và Huakang Li [4] đề xuất mô hình Bayesian-LSTM (B-LSTM) cho việc dự đoán giá cổ phiếu. Sáu chỉ số của thị trường chứng khoán Trung Quốc tại mỗi ngày là đầu vào cho LSTM. Để đại diện cho làn sóng kinh tế, họ đã xác định một đơn vị tập dữ liệu theo tuần có nghĩa là đơn vị cơ bản trong LSTM là dữ liệu trong một tuần. Hơn nữa, mô hình sẽ tìm kiếm số phiên đầu vào của dữ liệu tùy thuộc vào chu kỳ của nền kinh tế. Các kết quả thực nghiệm đã chứng minh rằng B-LSTM cho kết quả chính xác hơn 25% so với LSTM thông thường.

### B. Số đầu vào sử dụng

Đối với mô hình dự đoán đơn giản, chỉ cần một đầu vào là đủ. Tuy nhiên, trong hầu hết các trường hợp, chỉ có một đầu vào không thể đáp ứng đòi hỏi sự chính xác. Năm 2015, Kai Chen và Yi Zhou [5] có đã xem xét kỹ ảnh hưởng của số lượng đầu vào đến độ chính xác trong dự đoán chứng khoán. Từ công việc của họ, người ta có

thể thấy rằng kích thước đầu vào càng nhiều, độ chính xác sẽ đạt được. Với tất cả 5 đầu vào open, close, high, low, value có thể đưa ra dự đoán. Ngoài ra, các hiệu ứng của số lượng đầu vào được trình bày bởi Ryo Akita [6], khi sử dụng thông tin bằng số và văn bản cho dự đoán cổ phiếu. Kết quả là tương tự, càng nhiều đầu vào, nhiều yếu tố sẽ được xem xét, cuối cùng sẽ dẫn đến kết quả tốt hơn. Tuy vậy trong thực tế có một số đầu vào không có đầy đủ tất cả thông tin cho tất cả các phiên, gây rối loạn cho mô hình. Vì vậy chúng tôi chỉ sử dụng 4 cột đầu vào mà có sự đảm bảo về độ đầy đủ của dữ liệu là <Open>, <Close>, <High>, <Low>.

### C. Tối ưu hoá Bayesian

Tối ưu hóa Bayesian là một cách tiếp cận dựa trên mô hình xác suất để tìm mức tối thiểu của bất kỳ hàm nào trả về số liệu giá trị thực. Hàm này có thể đơn giản như  $f(x) = x^2$  hoặc có thể phức tạp như hàm mất mát của các mạng học sâu đối với hàng trăm lựa chọn kiến trúc mô hình và siêu tham số. Các kết quả gần đây cho thấy tối ưu hóa siêu tham số Bayesian của các mô hình học máy hiệu quả hơn so với tìm kiếm thủ công, ngẫu nhiên hoặc lưới với:

- Hiệu suất tổng thể tốt hơn.
- Cần ít thời gian để tối ưu hoá.

Tối ưu hóa Bayesian với thuật toán TPE đã chứng minh được sự hiệu quả của mình trong việc tối ưu hóa siêu tham số trong hàng trăm kích thước cho kiến trúc thị giác [7]. Hiệu suất tối ưu hóa Bayesian thuật toán trong lựa chọn siêu tham số là ngoài cả mong đợi.

## III. Mô hình Bayesian-LSTM

Đối với LSTM, có rất ít tham số có thể được thay đổi. Tuy nhiên nếu coi cấu trúc của mô hình cũng là siêu tham số thì ta có thể kết hợp với các lớp LSTM lại với nhau và thêm cái các lớp khác để tạo thành một cấu trúc có thể tối ưu bằng tối ưu hoá Bayesian. Đối với bài báo này, các siêu tham số có thể tìm kiếm được thể hiện tại bảng I

TABLE I  
Các siêu tham số

Siêu tham số	Diễn giải
windows_size	Số lượng phiên đầu vào
drop_rate	Tỉ lệ drop tại lớp Dropout giữa lớp LSTM ẩn cuối cùng và lớp LSTM đầu ra
lstm_neuron_count	Số lượng neuron trong mỗi lớp LSTM. Các lớp LSTM có số lượng neuron giống nhau.
lstm_layer_count	Số lượng lớp LSTM trong mô hình kể cả lớp LSTM Input, LSTM Output, không tính lớp Dropout.

Mô hình Bayesian-LSTM được thể hiện tại hình 1. Nếu số lớp neuron quá nhiều dẫn đến việc thông tin bị phân tích quá mức, vừa mất thời gian huấn luyện,

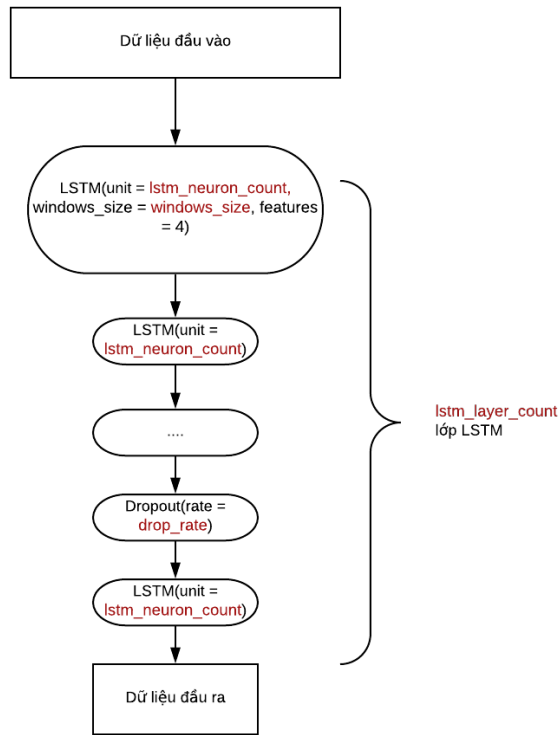


Fig. 1. Mô hình Bayesian-LSTM

vừa cho các quả bị overfitting. Nếu quá ít, thì thông tin phân tích không đủ, kết quả đưa ra bị hạn chế về độ chính xác. Số lượng neuron cũng tương tự vậy. Vì LSTM có số bước đầu vào là cố định nên ta phải tìm số ngày cụ thể đó. Ngoài ra trước khi cho ra kết quả, chúng tôi cho dữ liệu đi qua một lớp dropout để hạn chế tình trạng overfitting, chỉ số dropout có thể lên tới 0.7 để hạn chế việc dữ liệu giao động mạnh ảnh hưởng tới kết quả dự đoán. Việc lạm dụng dropout, luôn chèn lớp dropout vào giữa 2 lớp LSTM có thể dẫn đến việc mất mát thông tin, mô hình không học được gì, dẫn đến việc mô hình không quan tâm đến đầu vào, mọi kết quả đầu ra đều giống nhau. Vì vậy chúng tôi chỉ chèn 1 lớp dropout vào giữa lớp ẩn cuối cùng và lớp output.

Dữ liệu đầu vào:

- Giá trị của 4 cột <Open>, <Close>, <High>, <Low> trong từ phiên thứ  $t$  đến phiên thứ  $t + \text{windows\_size} - 1$ .

Dữ liệu đầu ra:

- Giá trị của cột <Close> phiên thứ  $t + \text{windows\_size}$ .

#### IV. Tìm kiếm siêu tham số thích hợp - Tối ưu hoá Bayesian

Phần quan trọng nhất trong Bayesian-LSTM là xác định các siêu tham số chính xác và nhanh chóng. Vấn đề với tối ưu hoá siêu tham số là việc đánh giá hàm mục tiêu để

tìm điểm là cực kỳ tốn kém. Mỗi lần thử các siêu tham số khác nhau, chúng ta phải huấn luyện lại mô hình và tiến hành xác minh lại trên tập dữ liệu xác minh. Với một số lượng lớn các siêu tham số và các mô hình phức tạp như quần thể hoặc mạng lưới thần kinh học sâu có thể mất nhiều ngày để đào tạo, quá trình này nhanh chóng trở nên khó thực hiện bằng tay. Tối ưu hoá Bayesian là một giải pháp tối để tìm kiếm các siêu tham số tối ưu một cách hiệu quả. Tối ưu hoá Bayesian là một cách tiếp cận dựa trên mô hình xác suất để tìm mức tối thiểu của bất kỳ hàm nào trả về số liệu giá trị thực. Mặc dù hàm không có biểu thức, khi đầu vào  $x$ , hàm tạo ra một đầu ra  $y$ . Khi một lượng dữ liệu  $(x, y)$  đủ lớn được cung cấp, thông qua tối ưu hoá Bayesian, hàm tham thể tương đương có thể được ước tính, để dự đoán cực trị. Có hai mục tiêu tối ưu hoá Bayesian, một để xây dựng hàm tương đương, hai là để tìm cực. Bayesian có thể cân nhắc ưu và nhược điểm khi đối mặt với hai mục tiêu mâu thuẫn và điều chỉnh tự động, để tìm cực.

Xây dựng một vấn đề tối ưu hoá trong tối ưu hoá Bayesian yêu cầu bốn phần:

- Hàm mục tiêu: nhận đầu vào và trả lại chỉ số mất mát để tối thiểu. Trong Bayesian-LSTM hàm mục tiêu chính là mô hình với đầu vào là các siêu tham số.
- Không gian miền: phạm vi của các giá trị đầu vào để đánh giá. Trong Bayesian-LSTM, không gian miền định nghĩa xác suất của các siêu tham số.
- Thuật toán tối ưu hoá: phương pháp được sử dụng để xây dựng hàm thay thế và chọn các giá trị tiếp theo để đánh giá. J. Bergstra, D. Yamins and D. D. Cox đã thực nghiệm với Tree Parzen Estimator (TPE) [7], so sánh với việc tìm kiếm lưới và ngẫu nhiên cho thấy TPE cùng với một nguồn tài nguyên thì hiệu quả của TPE cao hơn. Vì vậy thuật toán được sử dụng để tìm kiếm trong Bayesian-LSTM là TPE.
- Kết quả: điểm số, cặp giá trị đầu vào và điểm số mà thuật toán sử dụng để xây dựng mô hình thay thế.

Các bước thuật toán tối ưu hoá Bayesian hoạt động:

- 1) Xây dựng mô hình xác suất thay thế của hàm mục tiêu
- 2) Tìm các siêu tham số tốt nhất trên hàm thay thế
- 3) Áp dụng các siêu tham số cho hàm mục tiêu thực sự
- 4) Cập nhật mô hình thay thế kết hợp các kết quả mới
- 5) Lặp lại các bước 2 đến bước 4 cho đến khi đạt được số lần lặp tối đa hoặc hết thời gian

#### V. Kết quả thực nghiệm

##### A. Dữ liệu đầu vào

Giá của mã cổ phiếu theo ngày Sinopec (mã cổ phiếu 600028) trên sàn chứng khoán Thượng Hải được lấy trên trang money.163.com. Chủ quản của trang web money.163.com là công ty Netease, một ông lớn internet trên thị trường Trung Quốc nên nguồn thông tin có thể

đảm bảo. Sinopec là một trong những tập đoàn dầu khí lớn nhất thế giới và đã tham gia sàn chứng khoán Thượng Hải vào năm 2001.

Thời gian thực nghiệm 10 năm là từ 01/01/2006 đến 19/10/2016. 70% là tập huấn luyện, 10% dùng để xác minh và 20 % cuối cùng dùng để đánh giá thử nghiệm. Trong 80% tập huấn luyện và xác minh, dữ liệu 2 năm cuối dùng để chạy thuật toán tối ưu hoá Bayesian nhằm tìm ra siêu tham số thích hợp.

Các miền giá trị của các siêu tham số được thể hiện tại bảng II .Số lần chạy để tìm kiếm siêu tham số là 100.

TABLE II  
Miền giá trị siêu tham số

Siêu tham số	Miền giá trị
windows_size	Số nguyên có giá trị từ 1 . đến 8. Là bội số của 1
drop_rate	Phân phối xác suất liên tục của một biến ngẫu nhiên có logarit được phân phối bình thường. Giá trị kỳ vọng = $\log(0,04)$ Phương sai $\sigma^2 = 1$ Giá trị lớn nhất là 0.7
lstm_neuron_count	Số nguyên có giá trị từ 32 đến 512. Là bội số của 32.
lstm_layer_count	Số nguyên có giá trị từ 3 đến 7. Là bội số của 1

## B. Dữ liệu đầu ra

Để có đối chiếu và so sánh với kết quả với mô hình ELSTM do X. Pang, Y. Zhou, P. Wang, W. Lin và V. Chang [1] đề xuất. Chúng tôi sử dụng chỉ số mất mát Mean Square Error (MSE).

$$MSE = \frac{1}{n} \sum_{t=1}^n (A_t - f_t)^2 \quad (1)$$

Trong đó:

- $A_t$  là giá <Close> thực tế tại phiên thứ  $t$ .
- $F_t$  là giá <Close> dự đoán tại phiên thứ  $t$ .

## C. So sánh các mô hình

Kết quả giá trị của các siêu tham số cho bộ dữ liệu của Sinopec được hiển thị ở bảng III

TABLE III  
Miền giá trị siêu tham số

Siêu tham số	Giá trị
windows_size	1
drop_rate	0.7
lstm_neuron_count	416
lstm_layer_count	4

Các mô hình ELSTM, DBN, DBN-MLP và Multilayer Perceptrons (MLP) được thử nghiệm trên bộ dữ liệu Sinopec trên chỉ số đo độ mất mát MSE. Kết quả được hiển thị ở bảng IV

TABLE IV  
So sánh MSE trên Sinopec

Mô hình	MSE
DBN	0.0019
DBN-MLP	0.0027
MLP	0.0022
ELSTM	0.0019
Bayesian-LSTM	0.0015

Cho kết quả dự đoán của Sinopec, kết quả dự đoán của các phương pháp gần tương tự nhau. Từ bảng IV ta có thể thấy kết quả tốt nhất về chỉ số MSE là Bayesian-LSTM, tốt hơn 20% so với ELSTM.

Sử dụng ELSTM để dự đoán, ta có thể thấy ở hình 2 khoảng chênh lệch giữa ở đoạn sau khá lớn, có những bước nhảy chênh lệch lớn so với thực tế. Hình dạng của giá trị dự đoán và thực tế ở khoảng đầu khá là đồng đều nhưng đến nửa phần sau, sự khác biệt được hiển thị một cách rõ ràng, xu hướng tăng giảm có sự sai lệch đáng kể so với thực tế. Có những lúc giá trị dự đoán thấp một cách đột ngột, đến phiên hôm sau lại cao một cách bất thường, cắt ngang đường giá trị thực tế. Như vậy hình dạng của giá trị dự đoán đưa ra bởi mô hình ELSTM không được mượt.

So với kết quả dự đoán đưa ra tại hình 3, nửa giai đoạn đầu có sự tương đồng tương đối, đặc biệt là giao đoạn ở giữa, giá trị dự đoán và giá trị thực tế không có nhiều sự khác biệt. Nửa giao đoạn sau, tuy có sự chênh lệch tương đối nhưng giá dự đoán vẫn đưa ra được xu hướng tăng giảm chính xác. Sự chênh lệch của mô hình Bayesian-LSTM nhỏ hơn hẳn sự chênh lệch của ELSTM. Phần giao động biến thiên của Bayesian-LSTM theo phiên bị thu nhỏ lại so với giá trị thực tế. Với dropout rate cao, giá trị dự đoán có vẻ mượt hơn so với thực tế.

## VI. Kết luận

Trong bài báo này, mạng Bayesian-LSTM được đề xuất là sự kết hợp giữa thuật toán tối ưu hoá Bayesian và mạng LSTM. Bằng cách sử dụng một tập dữ liệu trong tập huấn luyện và xác minh cho mạng LSTM trong thuật toán tối ưu hoá Bayesian, một bộ siêu tham số được đề xuất. Sử dụng bộ siêu tham số để huấn luyện thực nghiệm trên bộ dữ liệu thử nghiệm cho kết quả chỉ số MSE thấp hơn mạng ELSTM [1]20%. Việc tối ưu hoá từng bộ tham số riêng cho mỗi mã cổ phiếu có thể đem lại kết quả tốt hơn so với việc sử dụng chung bộ tham số cho tất cả các mã cổ phiếu.

Tuy vậy có một số thiếu sót lớn khi chỉ sử dụng lịch sử giá. Các thông tin ngữ cảnh khác như tin tức chưa được khai thác đầu đủ. Ngoài ra việc xây dựng mô hình dự đoán chỉ thay vì chỉ sử dụng mạng LSTM, có thể kết hợp thêm các mạng khác tạo thành cấu trúc phức tạp. Việc lựa chọn miền phân phối các siêu tham số cũng là một chỉ tiêu có thể cải tiến.

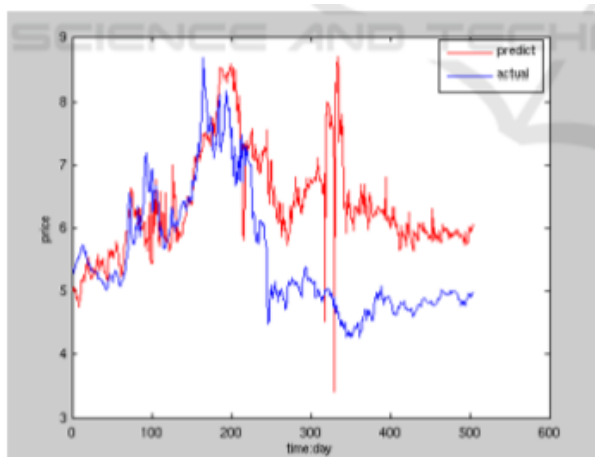


Fig. 2. So sánh giá trị thực tế và dự đoán trên Sinopec của ELSTM



Fig. 3. So sánh giá trị thực tế và dự đoán trên Sinopec của Bayesian-LSTM

## References

- [1] X. Pang, Y. Zhou, P. Wang, W. Lin and V. Chang, "An innovative neural network approach for stock market prediction", *The Journal of Supercomputing*, 2018. Available: 10.1007/s11227-017-2228-y.
- [2] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory", *Neural Computation*, vol. 9, no. 8, pp. 1735-1780, 1997. Available: 10.1162/neco.1997.9.8.1735.
- [3] A. Adebiyi, A. Adewumi and C. Ayo, "Comparison of ARIMA and Artificial Neural Networks Models for Stock Price Prediction", *Journal of Applied Mathematics*, vol. 2014, pp. 1-7, 2014. Available: 10.1155/2014/614342.
- [4] B. Huang, Q. Ding, G. Sun and H. Li, "Stock Prediction based on Bayesian-LSTM," *ICMLC 2018: Proceedings of the 2018 10th International Conference on Machine Learning and Computing*, p. 128-133, 2018.
- [5] C. Kai, Z. Yi and D. Fangyan, "A LSTM-based method for stock returns prediction: A case study of China stock market," in *2015 IEEE International Conference on Big Data (Big Data)*, Santa Clara, CA, USA, 2015.
- [6] R. Akita, A. Yoshihara, T. Matsubara and K. Uehara, "Deep learning for stock prediction using numerical and textual information," in *2016 IEEE/ACIS 15th International Conference on Computer and Information Science (ICIS)*, Okayama, Japan, 2016.
- [7] J. Bergstra, D. Yamins and D. D. Cox, "Making a science of model search: hyperparameter optimization in hundreds of dimensions for vision architectures," *ICML'13: Proceedings of*

the 30th International Conference on International Conference on Machine Learning, vol. 28, pp. I-115-I-123, 2013.